

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Beatriz Prado Soche (RA: 176112)

Repositório / Código Reprodutível:

<https://github.com/biaaPrado/redes-neurais/tree/main/Projeto%20-%20Baseline>

1. Configuração Experimental e Reprodutibilidade

1.1. Pré-processamento e Partição dos Dados

O dataset fornecido contém 300 amostras com uma única variável de entrada $x \in [0, 10]$ e uma variável-alvo y (regressão), sem valores nulos ou duplicados. A análise exploratória (correlação com x , x^2 , $\sin(x)$, $\sqrt{x}$ e $\log(x + 1)$, todas próximas de zero) indicou uma relação claramente **não-linear e não-monotônica** entre x e y , o que motivou o uso de uma rede MLP com ativação tanh nas camadas ocultas, capaz de aproximar funções não-lineares complexas.

A partição dos dados seguiu estritamente a proporção de **10% para treino** (30 amostras), **10% para validação** (30 amostras) e **80% para teste** (240 amostras). Essa restrição intencional no volume de treino torna a tarefa suscetível ao sobreajuste, tornando a investigação de hiperparâmetros e técnicas de regularização crítica.

Para garantir que **todas** as comparações (baseline e as quatro variações de ablação) fossem avaliadas exatamente na mesma divisão dos dados, os índices foram embaralhados com uma semente fixa ($\text{seed} = 42$) e a partição resultante foi persistida em disco na primeira execução; execuções subsequentes apenas recarregam essa mesma divisão, eliminando qualquer variabilidade decorrente de um novo sorteio aleatório.

A variável de entrada x foi padronizada (média 0, desvio-padrão 1) para evitar saturação da ativação tanh nas primeiras camadas — essencial dado o uso de SGD puro, sem otimizador adaptativo que compensasse entradas em escalas muito distintas. O cálculo de média/desvio (*fit*) ocorreu exclusivamente sobre os 10% de treino, aplicando-se apenas o *transform* às partições de validação e teste, mitigando vazamento de dados (*data leakage*). A variável-alvo y não foi reescalada, por já se encontrar em uma faixa numérica pequena ($\approx -1,5$ a $2,7$), o que também torna as métricas finais diretamente interpretáveis na escala original.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* é uma rede MLP básica treinada estritamente com **SGD padrão** (sem aceleradores adaptativos como Adam e sem termo de *momentum*, isto é, $\text{momentum} = 0$ e $\text{weight_decay} = 0$ no otimizador). Nenhuma regularização explícita (L1, L2, Dropout) foi aplicada nesta fase.

A busca empírica pela melhor configuração envolveu duas etapas. Primeiro, uma busca ampla variou sistematicamente o número de camadas ocultas (1 e 2), o número de neurônios (8, 16, 32 e 64, além de combinações de 2 camadas) e a taxa de aprendizado inicial ($\eta \in \{0.01, 0.05, 0.1, 0.5, 1.0\}$), por 500 épocas cada, avaliando-se o desempenho estritamente pelo menor erro (MSE) na validação. Observou-se que $\eta \geq 0.5$ diverge sistematicamente com ativação tanh e inicialização de Xavier, e que arquiteturas com 2 camadas ocultas superaram consistentemente as de 1 camada. Em uma segunda etapa, os candidatos mais promissores foram treinados por um número de épocas muito maior, revelando que o SGD puro converge **lentamente** neste problema (a perda de validação ainda melhorava mesmo após milhares de épocas adicionais) — achado que se tornaria central na discussão do componente de Momentum (Seção 3). A Tabela 1 detalha o espaço de busca e a configuração final selecionada.

A opção pelo *checkpoint* do melhor ponto de validação (em vez de um critério de paciência) foi aplicada de forma **idêntica a todos os modelos** do estudo (baseline e as quatro ablações), portanto não favorece nenhuma técnica em particular — é apenas um critério neutro para reportar "qual versão" de cada modelo treinado.

Table 1: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida (Vanilla)
Topologia das Camadas	1 e 2 camadas ocultas; {8, 16, 32, 64} neurônios	Entrada(1) → Densa(16) → Densa(8) → Saída(1)
Função de Ativação	tanh	tanh nas ocultas; saída linear (regressão)
Otimizador	SGD Padrão	SGD ($\eta = 0.1$)
Tamanho do Lote	Fixado em 8 durante a busca de arquitetura/lr (ver Seção 4)	8
Função de Custo	Erro Quadrático Médio (MSE)	MSELoss
Critério de Parada	Sem <i>early stopping</i> por paciência: treino completo por 3000 épocas, com <i>checkpoint</i> no ponto de menor erro de validação	Modelo restaurado à época de menor MSE de validação
Sementes Aleatórias	Seed fixa para a divisão dos dados; seed fixa e idêntica em todos os modelos para a inicialização dos pesos	seed divisão = 42; seed inicialização = 123

2. Dinâmica de Treinamento e Convergência (Baseline vs. Modificados)

A evolução das curvas de função de perda (MSE) ao longo das épocas foi monitorada para verificar a estabilidade do SGD e comparar a dinâmica do *baseline* com os modelos contendo componentes adicionais (Figuras 1 e 2). Como as curvas de validação apresentam ruído considerável (calculadas sobre apenas 30 amostras), aplicou-se uma suavização por média móvel (janela de 51 épocas) apenas para fins de visualização, sem alterar nenhum valor reportado nas tabelas de métricas.

Análise Crítica da Dinâmica de Convergência:

- **Estabilidade do SGD:** sem termos adaptativos ou de momentum, a taxa de aprendizado precisou ficar numa faixa relativamente estreita: valores a partir de $\eta = 0.5$ causaram divergência franca do treino (perda explodindo), enquanto $\eta = 0.1$ produziu uma convergência estável, ainda que lenta e com oscilações visíveis época a época — esperado, já que cada mini-lote (tamanho 8, de apenas 30 amostras de treino) introduz ruído na estimativa do gradiente.
- **Sobreajuste (*Overfitting*):** no baseline, o erro de treino e o de validação já se descolam nas primeiras centenas de épocas, e a diferença se acentua ao longo do treino — ao final das 3000 épocas, o erro de treino continua caindo enquanto o de validação estagna/oscila em um patamar mais alto (Figura 1, painel Baseline), sinal característico de sobreajuste, coerente com o volume reduzido de dados de treino (30 amostras) frente à complexidade não-linear do problema. O mesmo padrão (treino caindo, validação estagnada) se repete nos demais painéis da Figura 1, com intensidade variável entre os modelos.
- **Aceleração com Momentum:** sim — o modelo com momentum atingiu seu melhor ponto de validação por volta da época 2050, contra 2628 do baseline puro (Figura 1), além de alcançar um patamar de erro de validação mais baixo dentro do mesmo orçamento de 3000 épocas (Figura 2). Esse resultado é coerente com a lentidão de convergência do SGD puro identificada na busca empírica (Seção 1.2): o momentum não atua como regularizador, mas acelera a otimização da mesma função de perda.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Para isolar rigorosamente o efeito de cada componente, a arquitetura base (camadas, ativações, número de épocas, tamanho de lote e seed de inicialização) foi mantida idêntica à da Tabela 1 em todas as variações a seguir — a única mudança em cada uma é a ativação de um único componente adicional:

1. **Baseline + Momentum:** SGD com fator de momentum $\beta = 0.7$.
2. **Baseline + Regularização L2 (*Weight Decay*):** penalização quadrática dos pesos, $\lambda_{L2} = 10^{-4}$, implementada via o parâmetro `weight_decay` do otimizador.
3. **Baseline + Regularização L1 (Lasso):** penalização por norma L_1 , $\lambda_{L1} = 10^{-4}$, somada manualmente à função de perda antes do *backward pass* (o PyTorch não oferece suporte nativo a L1 no otimizador, ao contrário do L2).
4. **Baseline + Dropout:** desativação aleatória de neurônios nas camadas ocultas com $p = 0.1$.




Figure 1: Evolução do treino (treino x validação) para os 5 modelos do estudo. A linha tracejada vertical marca a época do *checkpoint* (menor erro de validação).




Figure 2: Comparação de convergência na validação — Baseline vs. L1, L2, Dropout e Momentum.

Os quatro valores de intensidade acima (β , λ_{L1} , λ_{L2} , p) foram, eles próprios, escolhidos por meio de uma busca empírica independente (testando 5 valores para cada técnica e selecionando o de menor MSE de validação), de modo a comparar o baseline com a *melhor versão razoável* de cada técnica, e não com um valor arbitrário. Não foi avaliado um modelo combinando múltiplos componentes simultaneamente, pois o escopo do estudo de ablação é isolar o efeito de **um único** componente por vez frente ao baseline; a combinação de técnicas é discutida como extensão futura na Seção 5.

A avaliação final foi realizada sobre os 80% de dados de teste, não utilizados no treino nem na escolha de hiperparâmetros. Os resultados comparativos estão organizados na Tabela 2.

Table 2: Resultados do Estudo de Ablação no Conjunto de Teste (80% dos dados).

Modelo / Variação	MSE	RMSE	MAE	R^2	Época do checkpoint
Baseline Vanilla (SGD sem momentum)	0,382	0,618	0,489	0,260	2628
Baseline + Regularização L2 ($\lambda = 10^{-4}$)	0,397	0,630	0,497	0,231	2441
Baseline + Regularização L1 ($\lambda = 10^{-4}$)	0,412	0,642	0,506	0,201	2730
Baseline + Momentum ($\beta = 0.7$)	0,417	0,646	0,501	0,191	2050
Baseline + Dropout ($p = 0.1$)	0,509	0,713	0,574	0,013	2811

Valores gerados a partir de `results/tables/metricas_comparativas.csv`. Pequenas variações de arredondamento (na 3ª/4ª casa decimal) podem ocorrer entre execuções em máquinas/SOs diferentes, mesmo com sementes fixas.

Vale destacar que a ordem de desempenho no conjunto de **validação** (usada para selecionar hiperparâmetros e o ponto de *checkpoint*) não coincide exatamente com a ordem observada no **teste**: na validação, o Momentum apresentou o menor erro; no teste, é o Baseline puro que apresenta o melhor R^2 . Essa discrepância é discutida na Seção 5.

A Figura 5 permite uma leitura qualitativa complementar à Tabela 2: Baseline, L1 e L2 aprendem curvas praticamente indistinguíveis entre si; o Dropout produz uma curva visivelmente mais "achatada", perdendo parte das oscilações do padrão real; e o Momentum captura as oscilações com maior amplitude, ainda que isso não se traduza necessariamente em melhor generalização no teste (Tabela 2).




Figure 3: Dispersão real vs. predito no teste ($y = x$) — Baseline vs. Baseline+Momentum.




Figure 4: Resíduos ($\hat{y} - y$) do modelo Baseline+Momentum no conjunto de teste.




Figure 5: Função aprendida por cada modelo (linha vermelha) sobreposta aos dados reais (pontos), no domínio completo de x .

4. Análise de Sensibilidade a Hiperparâmetros

Além do estudo de ablação (Seção 3), avaliou-se a sensibilidade do modelo *baseline* a três hiperparâmetros de treino — taxa de aprendizado, taxa de *dropout* e tamanho de lote — variando cada um isoladamente a partir de um ponto de referência já estabelecido no projeto (arquitetura, época e demais hiperparâmetros mantidos fixos). Diferentemente da busca empírica da Seção 1.2 (cujo objetivo era *encontrar* o melhor valor), esta análise tem caráter didático: mostrar o que ocorre ao nos afastarmos do valor já escolhido.

Para os testes de taxa de aprendizado e tamanho de lote, a referência utilizada foi o próprio **Baseline oficial** ($\eta = 0.1$, *dropout*= 0, lote= 8). Para os testes de *dropout*, a referência foi a própria ablação **Baseline + Dropout** oficial ($\eta = 0.1$, lote= 8, *dropout*= 0.1) — evitando ancorar as comparações em um modelo "híbrido" que nunca fez parte do estudo principal.

Taxa de aprendizado (Figura 6): $\eta = 0.01$ resultou em convergência muito mais lenta, não atingindo, mesmo ao final das 3000 épocas, o patamar de erro alcançado pela referência — evidenciando que uma taxa de aprendizado baixa demais pode ser tão prejudicial, dentro de um orçamento fixo de épocas, quanto uma taxa alta demais que diverge. Já $\eta = 0.3$ apresentou trajetória mais ruidosa que a referência, mas convergiu para um patamar final semelhante, indicando alguma margem de tolerância acima de $\eta = 0.1$ antes da instabilidade observada na busca ampla (Seção 1.2, $\eta \geq 0.5$).




Figure 6: Sensibilidade à taxa de aprendizado ($\eta = 0.01, 0.1$ e 0.3), com $dropout=0$ e lote=8 fixos.

Taxa de *dropout* (Figura 7): de forma notável, $p = 0.05$ (mais leve que o valor oficialmente escolhido) obteve erro de validação *menor* que a própria referência ($p = 0.1$) ao longo de praticamente todo o treino, enquanto $p = 0.3$ piorou substancialmente o resultado. Esse gradiente reforça a conclusão da Seção 3 de que o *dropout* prejudica esta rede pequena **proporcionalmente à sua intensidade** — mesmo o valor "ótimo" encontrado na busca de ablação ($p = 0.1$) já não é a escolha ideal quando comparado a valores ainda mais leves, sugerindo que, para esta arquitetura e este volume de dados, quanto menor a taxa de *dropout*, melhor (o caso limite sendo não usar *dropout* algum, isto é, o próprio Baseline).




Figure 7: Sensibilidade à taxa de *dropout* ($p = 0.05, 0.1$ e 0.3), com $\eta = 0.1$ e lote=8 fixos.

Tamanho de lote (Figura 8): lote=1 produziu uma curva visivelmente mais ruidosa que a referência (lote=8), como esperado dado o gradiente estimado a partir de uma única amostra por atualização, mas convergiu para um patamar final semelhante. Lote=30 (lote completo, já que o treino tem exatamente 30 amostras) apresentou a convergência mais lenta dentre os três — no início do treino permanece com erro visivelmente mais alto que os demais, embora se aproxime da referência ao final das 3000 épocas — confirmando o trade-off esperado entre suavidade do gradiente (menos ruído por atualização) e velocidade de convergência (menos atualizações por época).




Figure 8: Sensibilidade ao tamanho de lote (1, 8 e 30), com $\eta = 0.1$ e $dropout = 0$ fixos.

5. Discussão e Lições Aprendidas

- Impacto do SGD Vanilla no Regime de Poucos Dados (10% de Treino):** com apenas 30 amostras de treino para uma função não-linear com múltiplas oscilações, o baseline já apresenta sinais claros de sobreajuste (erro de treino $R^2 \approx 0.59$ contra $R^2 \approx 0.26$ no teste). Entre as técnicas de regularização avaliadas (L1, L2, Dropout), **nenhuma reduziu essa variância de forma expressiva** nas intensidades ótimas encontradas — L1 e L2 tiveram desempenho de teste praticamente equivalente (ligeiramente pior, na verdade) ao do baseline, e o Dropout piorou claramente o resultado em todos os conjuntos. Uma hipótese para esse comportamento é que a rede já é pequena (177 parâmetros) e o conjunto de treino já é escasso, restando pouca "capacidade excedente" para essas penalidades cortarem sem prejudicar o ajuste.
- Ação Específica dos Hiperparâmetros de Ablação:**
 - O *momentum* alterou visivelmente a velocidade da curva de validação (melhor época ≈ 2050 , contra 2628 do baseline), sem necessariamente suavizá-la — ambas as curvas permanecem ruidosas, dado o tamanho reduzido do conjunto de validação (30 amostras).
 - Houve diferença observável, mas sutil, entre L1 e L2: ambos obtiveram desempenho de teste muito próximo (L2 ligeiramente melhor que L1), e ambos ficaram muito próximos do baseline nas intensidades ótimas — indicando que, neste regime de poucos dados, a diferença conceitual entre esparsidade (L1) e atenuação suave dos pesos (L2) teve efeito prático limitado sobre o erro final.
 - O *Dropout*, mesmo na intensidade mais leve avaliada na busca ($p = 0.1$), já piorou o erro de treino e de teste em relação ao baseline — indicando que, para esta arquitetura pequena, o dropout reduz a capacidade efetiva da rede a ponto de prejudicar o ajuste, em vez de apenas conter o sobreajuste.
 - Os resultados da Análise de Sensibilidade (Seção 4) mostram que o modelo é mais sensível ao *dropout* do que ao *learning rate* ou ao *batch size* dentro das faixas testadas: pequenas variações na taxa de *dropout* (mesmo abaixo do valor "ótimo" de 0.1) já produzem mudanças visíveis no erro de validação, enquanto η e o tamanho de lote toleram variações maiores sem uma degradação tão acentuada dentro do orçamento de 3000 épocas.
- Análise de Resíduos e Limitações:** o gráfico de dispersão real vs. predito (Figura 3) mostra que ambos os modelos capturam a tendência geral, mas com dispersão considerável em torno da diagonal — coerente com o R^2 moderado obtido. Os resíduos (Figura 4) não mostram um viés

sistemático evidente (distribuição aproximadamente centrada em zero), mas a inspeção do gráfico de função aprendida sugere maior dificuldade do modelo na região de x entre aproximadamente 6 e 8, onde a cobertura de exemplos de treino é mais esparsa.

- **Honestidade estatística — validação vs. teste:** a técnica selecionada como "melhor" depende do conjunto usado como critério. Como o conjunto de validação tem apenas 30 amostras (alta variância), a escolha de hiperparâmetros baseada nele nem sempre generaliza da mesma forma para uma amostra de teste $8\times$ maior. Isso reforça a importância de reportar métricas de teste — e não apenas de validação — antes de afirmar que uma técnica é definitivamente superior às demais.