Projeto 2: Quantização de Cores com SOM e GNG

Disciplina: Redes Neurais Artificiais — UNIFESP

Autor(es): Beatriz Prado Soche (RA: 176112)

Repositório / Código Reprodutível: https://github.com/biaaPrado/redes-neurais/tree/main/Projeto%202%20-%20SOM%20e%20GNG

1. Configuração Experimental e Reprodutibilidade

1.1. Dados e Pré-processamento

Cada imagem colorida foi tratada como um conjunto de dados tridimensional: cada pixel é uma amostra $\mathbf{x} \in \mathbb{R}^3$ com os canais *Red*, *Green* e *Blue*. Foram utilizadas **5 imagens** (mínimo exigido), todas com pelo menos 100×100 px, escolhidas para estressar a quantização de formas distintas (Tabela 1). Imagens maiores tiveram o lado menor reduzido para 128 px, preservando a proporção, apenas para limitar o tempo de treino.

Os valores foram normalizados por **Min-Max**, calculada separadamente em cada canal $c \in \{R, G, B\}$:

$$x'_c = \frac{x_c - \min(x_c)}{\max(x_c) - \min(x_c)} \in [0, 1]. \tag{1}$$

Todo o treinamento e todas as métricas operam no espaço normalizado; a transformação inversa é aplicada somente para **exibir** as imagens com as cores originais. Por se tratar de aprendizado não supervisionado cujo objetivo é comprimir *a própria imagem*, não há partição treino/validação/teste: os pixels da imagem são usados no treino e na avaliação (ver limitações na Seção 4).

Table 1: Imagens utilizadas. Dimensões após a redução do lado menor.

Imagem	Tipo de desafio	Dimensão (px)	Fonte
`altaSaturacao`	Cores saturadas, uso amplo do cubo RGB	171×128	fonte/autor
`corRara`	Cor rara e relevante em cena dominante	192×128	fonte/autor
`paisagem`	Degradês suaves (céu/água)	192×128	fonte/autor
`paisagem2`	Degradês suaves (céu/água)	192×128	fonte/autor
`retratoHumano`	Tons de pele (variação sutil)	193×128	fonte/autor

1.2. Arquiteturas Fixas e Espaço de Hiperparâmetros

As **redes são fixas**: SOM com grades 4×4, 8×8 e 16×16 (16, 64 e 256 neurônios) e GNG com no máximo 16, 64 e 256 neurônios. Somente os hiperparâmetros da Tabela 2 foram variados. O SOM foi implementado com a biblioteca *MiniSom* (topologia retangular, vizinhança gaussiana, pesos iniciais sorteados dentre os pixels); o GNG foi implementado diretamente em NumPy. Com as combinações da tabela, cada imagem gera 42 treinamentos (3×6 do SOM + 3×8 do GNG), totalizando **210 simulações** nas 5 imagens (30 simulações-base, uma por par imagem × rede, cada uma repetida para todas as combinações de hiperparâmetros).

1.3. Inferência e Métricas de Avaliação

Na inferência, cada pixel é substituído pelo vetor de pesos do seu neurônio vencedor (BMU), e a matriz da imagem é reconstruída. Sendo N o número de pixels, $b_1(i)$ e $b_2(i)$ o primeiro e o segundo neurônios mais próximos de $\mathbf{x}_i$ e $\mathbf{w}$ os pesos:

$$\mathrm{QE} = \frac{1}{N}\sum_{i=1}^{N} \|\mathbf{x}_i - \mathbf{w}_{b_1(i)}\|_2, \qquad \mathrm{TE} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{1}[b_1(i) \not\sim b_2(i)], \tag{2}$$

$$\mathrm{MSE} = \frac{1}{3N}\sum_{i=1}^{N} \|\mathbf{x}_i - \mathbf{w}_{b_1(i)}\|_2^2, \qquad \mathrm{PSNR} = 10 \log_{10} \frac{1}{\mathrm{MSE}} \ [\mathrm{dB}]. \tag{3}$$

Table 2: Espaço de hiperparâmetros amostrado e padrão observado nas melhores configurações.

Parâmetro	**Valores testados**	**Melhor (menor QE)**
SOM (MiniSom), 20 000 iterações, semente 42		
σ_0 (raio inicial da vizinhança)	$0{,}5L$ e $0{,}25L$ (L = lado da grade)	$0{,}25L$ em **15/15** casos
η_0 (taxa de aprendizado inicial)	0,1; 0,5; 1,0	0,1 (16 neur., 5/5); 0,5 (64 neur., 4/5); sem padrão em 256
GNG, $\lambda = 100$, $\alpha = 0{,}5$, $d = 0{,}995$ fixos, semente 42		
ε_b (taxa do vencedor)	0,05; 0,2	0,05 (16 neur., 4/5); 0,2 (256 neur., 5/5)
ε_n (taxa dos vizinhos)	0,001; 0,006	0,001 (16 e 64 neur., 8/10); 0,006 (256 neur., 5/5)
$a_{\max}$ (idade máx. das arestas)	25; 50	25 em **4/5** imagens (256 neur.)
Nº de passos	$\lambda N_{\max} + 15\,000$	—

No SOM, $b_1 \sim b_2$ significa vizinhos na grade (distância de Chebyshev ≤ 1); no GNG, significa estarem ligados por uma aresta (erro topológico). Além disso, calculou-se o SSIM entre a imagem original e a reconstruída (canais RGB, `data_range`= 1). A melhor configuração de cada par (imagem, rede) foi escolhida pelo **menor QE**.

2. Efeito dos Hiperparâmetros e Dinâmica de Aprendizado

A Figura 1 mostra o QE médio (entre as imagens) de cada combinação de hiperparâmetros, para cada rede.

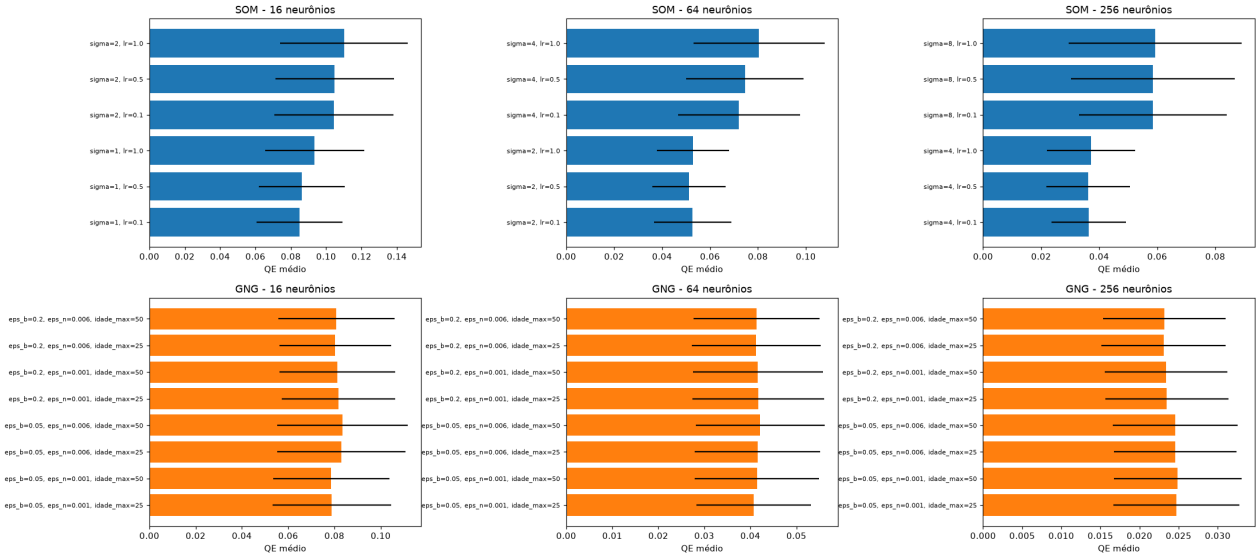


Figure 1: QE médio ± desvio padrão por combinação de hiperparâmetros (linha superior: SOM; inferior: GNG).

Análise Crítica:

- **Raio da vizinhança (SOM):** a menor vizinhança inicial testada ($0{,}25L$) venceu em todos os 15 casos (5 imagens × 3 grades). Como o valor ótimo está na **borda** do espaço de busca, é possível que valores ainda menores melhorem o QE; isso não foi testado. Um raio menor reduz a "puxada" coletiva dos vizinhos e deixa cada neurônio se ajustar mais à sua região de cores, o que favorece o QE (possivelmente à custa de topologia).
- **Taxa de aprendizado (SOM):** com 16 neurônios, $\eta_0 = 0{,}1$ foi a melhor em 5/5 imagens; com 64, $\eta_0 = 0{,}5$ em 4/5; com 256 não houve padrão (0,1; 0,5 e 1,0 aparecem como melhores).

Hipótese: grades pequenas têm poucos neurônios disputando muitos pixels e se beneficiam de passos menores, enquanto grades maiores toleram taxas altas.

- **Taxas do GNG:** com 16 neurônios, $(\varepsilon_b, \varepsilon_n) = (0{,}05;\ 0{,}001)$ venceu em 4/5 imagens; com 64, $\varepsilon_n = 0{,}001$ venceu em 4/5 (com ε_b dividido); com 256, o par $(0{,}2;\ 0{,}006)$ venceu em **5/5**. Hipótese: com muitos neurônios, cada um cobre poucos pixels e precisa se mover mais rápido para convergir no número de passos disponível.

- **Idade máxima das arestas:** $a_{\max} = 25$ foi preferido em 4 de 5 imagens com 256 neurônios, sugerindo que remover arestas mais cedo ajuda a manter o grafo atualizado enquanto os neurônios se deslocam.

- **Importância relativa dos hiperparâmetros:** no SOM, o raio σ_0 domina. Na média sobre todas as imagens e taxas, o σ_0 menor reduziu o QE em $\approx 17\%$ (16 neur.: 0,088 contra 0,107), $\approx 31\%$ (64: 0,052 contra 0,076) e $\approx 38\%$ (256: 0,037 contra 0,059). Já a taxa η_0 teve efeito pequeno: a diferença entre a melhor e a pior taxa foi de $\approx 7\%$, 6% e 2% do QE médio, respectivamente. No GNG, todas as 8 combinações ficaram próximas: o QE médio de cada combinação variou apenas $\approx 6\%$ (16 neur.: 0,0786 a 0,0835), 3% (64: 0,0407 a 0,0421) e 8% (256: 0,0231 a 0,0249). Ou seja, o GNG é **robusto** à escolha dos hiperparâmetros, enquanto o SOM é sensível ao raio da vizinhança. Com 64 e 256 neurônios, até a *pior* combinação média do GNG teve QE menor que a *melhor* do SOM (0,0249 contra $\approx$ 0,036 com 256 neur.).

- **Leitura das barras de erro:** as barras da Figura 1 representam o desvio padrão *entre imagens* (cada imagem tem um QE base muito diferente), e não a incerteza de cada combinação. Por isso elas se sobrepõem mesmo quando uma combinação é melhor que outra em todas as imagens; a comparação correta é a das barras entre si, não da sobreposição.

3. Resultados Quantitativos e Qualitativos

A Tabela 3 resume as métricas (média ± desvio padrão entre as 5 imagens, usando a melhor configuração de cada uma) e a Tabela 4 detalha o QE e o PSNR por imagem.

Table 3: Métricas por rede (média ± dp entre as 5 imagens; melhor configuração de cada imagem).

Modelo	Neur.	QE	TE	MSE	PSNR (dB)	SSIM
SOM	16	$0{,}0848 \pm 0{,}0244$	$0{,}0412 \pm 0{,}0305$	$0{,}0035 \pm 0{,}0017$	$24{,}92 \pm 2{,}15$	$0{,}779 \pm 0{,}073$
SOM	64	$0{,}0512 \pm 0{,}0153$	$0{,}0471 \pm 0{,}0542$	$0{,}0015 \pm 0{,}0008$	$28{,}71 \pm 2{,}01$	$0{,}889 \pm 0{,}039$
SOM	256	$0{,}0356 \pm 0{,}0136$	$0{,}0718 \pm 0{,}0763$	$0{,}0009 \pm 0{,}0006$	$31{,}30 \pm 2{,}72$	$0{,}935 \pm 0{,}031$
GNG	16	$0{,}0783 \pm 0{,}0247$	$0{,}0048 \pm 0{,}0023$	$0{,}0030 \pm 0{,}0018$	$25{,}80 \pm 2{,}64$	$0{,}794 \pm 0{,}067$
GNG	64	$0{,}0403 \pm 0{,}0131$	$0{,}0165 \pm 0{,}0059$	$0{,}0008 \pm 0{,}0005$	$31{,}68 \pm 2{,}90$	$0{,}912 \pm 0{,}033$
GNG	**256**	$\mathbf{0{,}0230 \pm 0{,}0079}$	$0{,}0219 \pm 0{,}0070$	$\mathbf{0{,}0003 \pm 0{,}0002}$	$\mathbf{36{,}62 \pm 3{,}01}$	$\mathbf{0{,}963 \pm 0{,}017}$

Table 4: QE e PSNR por imagem (melhor configuração). K = número de neurônios.

	QE, K=16		QE, K=256		PSNR (dB), K=256	
Imagem	SOM	GNG	SOM	GNG	SOM	GNG
`altaSaturacao`	0,1151	0,1126	0,0554	0,0334	27,1	33,0
`corRara`	0,0516	0,0447	0,0190	0,0124	33,9	41,0
`paisagem`	0,0862	0,0765	0,0319	0,0209	33,2	37,4
`paisagem2`	0,0990	0,0868	0,0412	0,0273	30,2	34,9
`retratoHumano`	0,0724	0,0707	0,0304	0,0211	32,2	36,8

Avaliação qualitativa. As Figuras 3 e 4 mostram, para o mesmo K, a imagem original, a reconstruída e a paleta de centroides efetivamente usados (cores dos neurônios que venceram ao menos um pixel).

O Apêndice A reúne as **30 reconstruções** (5 imagens × 6 redes), com GNG e SOM lado a lado.

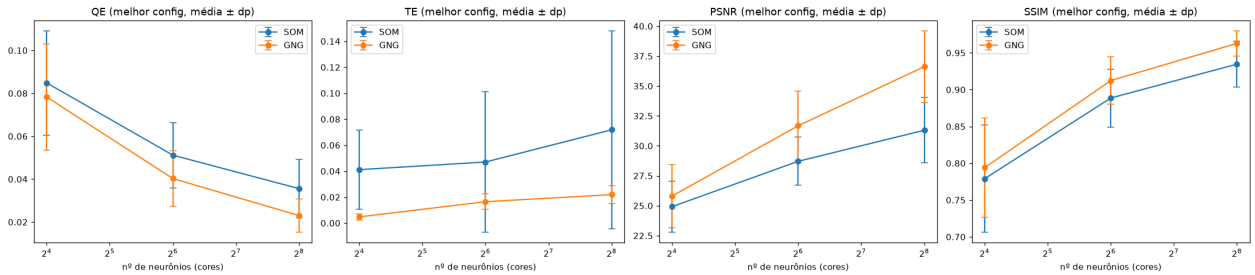


Figure 2: Comparação SOM × GNG em QE, TE, PSNR e SSIM (média ± dp entre as imagens).

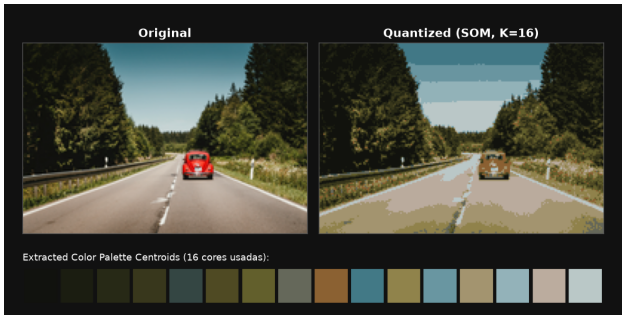


Figure 3: `corRara`: SOM, $K = 16$ (sem centroide vermelho: o carro fica marrom).

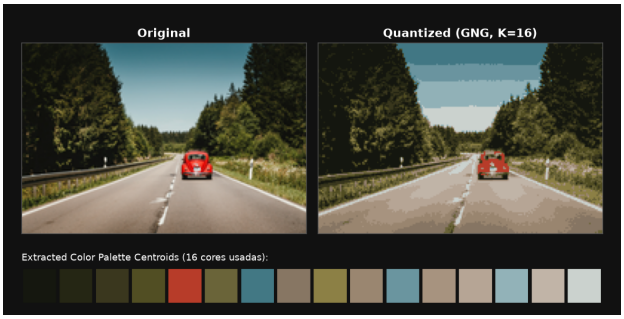


Figure 4: `corRara`: GNG, $K = 16$ (um centroide vermelho é preservado).

Observações qualitativas.

- ***Banding* nos degradês:** com $K = 16$, o céu de `paisagem`, `paisagem2` e `corRara` vira faixas horizontais de cor chapada em ambos os modelos (Figura 5), pois os poucos centroides não cobrem os tons intermediários. Com $K = 64$ o efeito já é bem mais discreto, e com $K = 256$ o GNG fica visualmente quase indistinguível do original (Figura 6).
- **Cor rara (`corRara`):** o carro vermelho ocupa poucos pixels. Com $K = 16$, a paleta do SOM não tem nenhum centroide vermelho e o carro sai marrom/laranja (Figura 3); o GNG preserva um centroide vermelho (Figura 4). O mapa de erro mostra o carro como a região mais clara no SOM com 16 e 64 neurônios, e ainda com um resíduo visível com 256, ao passo que no GNG com 256 neurônios o carro praticamente desaparece do mapa. Isso é coerente com o mecanismo do GNG, que insere neurônios onde o erro acumulado é maior, e não onde há mais pixels.
- **Retrato:** com $K = 16$, a pele do rosto aparece em manchas (patches) de tons próximos e o fundo desfocado vira blocos laranja; o erro se concentra nos contornos (cabelo e rosto) e na região mais saturada do fundo. Com $K \geq 64$ a pele fica contínua e com 256 neurônios a diferença para o original é difícil de perceber a olho nu.
- **Cores saturadas e balões (`altaSaturacao`, `paisagem2`):** com $K = 16$ as esferas perdem os reflexos e viram regiões planas; os balões de `paisagem2` perdem fidelidade de cor no SOM com 16 e 64 neurônios (aparecem destacados nos mapas de erro), enquanto o GNG os preserva melhor.
- **Onde fica o erro:** em todas as imagens o erro residual se concentra em **bordas e texturas finas** (folhagem, cabelo, contornos), e não em áreas uniformes. Isso explica por que o SSIM, sensível à estrutura local, sobe mais devagar que o PSNR.

4. Discussão e Lições Aprendidas

- **GNG × SOM em fidelidade de cor:** o GNG obteve QE menor que o SOM em todas as imagens e em todos os tamanhos de rede. A redução média do QE foi de ≈ 8% (16 neur.), ≈ 21% (64) e ≈ 35% (256), e o ganho médio de PSNR foi de +0,9, +3,0 e +5,3 dB, respectivamente.

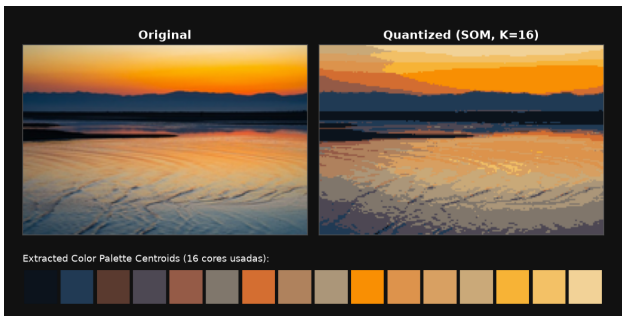


Figure 5: `paisagem`: SOM, $K = 16$ (efeito de *banding* no céu).

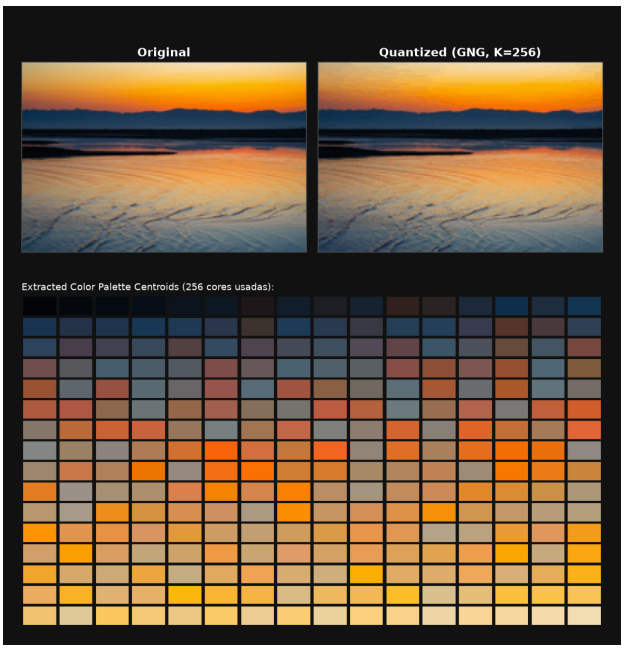


Figure 6: `paisagem`: GNG, $K = 256$.

A vantagem cresce com o número de neurônios: com poucas cores ambos só cobrem as cores dominantes (e com 16 neurônios o ganho médio de 0,9 dB é menor que a variação entre imagens, dp $\approx$ 2–3 dB, embora o GNG seja melhor nas 5 imagens), mas com 256 o GNG aloca neurônios onde o erro se acumula, ao passo que a grade fixa do SOM mantém neurônios em regiões pouco povoadas do espaço RGB para preservar a vizinhança.

- **Preservação topológica:** o TE médio do GNG (0,005 a 0,022) foi menor que o do SOM (0,041 a 0,072), e o SOM apresentou variação muito maior entre imagens (desvio de 0,076 com 256 neurônios; em `corRara`, TE = 0,195 com 256 e 0,133 com 64 neurônios). Uma grade 2D precisa "dobrar-se" para cobrir o cubo RGB, e pixels de uma mesma região passam a ter 1º e 2º BMU distantes na grade. Em ambos os modelos o TE médio **aumenta** com o número de neurônios. *Cautela:* as definições de adjacência diferem (grade $\times$ aresta) e, no GNG, a aresta entre os dois vencedores é criada durante o treino, o que favorece o TE por construção.

- **Dependência do conteúdo da imagem:** o conteúdo pesou tanto quanto o método. Com GNG de 256 neurônios, `corRara` atingiu 41,0 dB, contra 33,0 dB de `altaSaturacao`. Com 16 neurônios, `corRara` teve SSIM de 0,885, enquanto `altaSaturacao`, `paisagem` e `paisagem2` ficaram em $\approx$ 0,745: imagens saturadas e imagens com degradês longos (céu/água) são igualmente difíceis para poucas cores, as primeiras por dispersarem os pixels pelo cubo RGB e as segundas por exigirem muitos tons intermediários (*banding*).

- **Métricas nem sempre concordam:** em `altaSaturacao` com 16 neurônios, o GNG tem QE menor (0,1126 $\times$ 0,1151), mas o SOM tem SSIM ligeiramente maior (0,756 $\times$ 0,747). O QE mede distância de cor pixel a pixel; o SSIM mede estrutura local, daí a importância de reportar ambas e de inspecionar os mapas de erro.

- **Custo computacional e uso dos neurônios:** o tempo médio de treino do GNG foi maior, e a diferença cresce com a rede (0,86 s $\times$ 0,64 s com 16 neur.; 2,5 s $\times$ 0,94 s com 256 neur., ou seja, $\approx$ 2,7$\times$ mais lento), pois o GNG busca o vencedor entre os neurônios ativos, gerencia arestas e insere neurônios ao longo do treino. Nas melhores configurações, praticamente todos os neurônios foram usados por ao menos um pixel (em média 255,6 de 256 no SOM e 253,8 de 256 no GNG), isto é, não houve neurônios "mortos" relevantes.

- **Limitações:**

- *Viés de seleção:* o GNG teve 8 combinações de hiperparâmetros e o SOM, 6; como a melhor foi escolhida pelo menor QE, o GNG teve uma tentativa extra de "acertar".
- *Uma semente por configuração* (42): diferenças pequenas, sobretudo com 16 neurônios, podem ser ruído; o ideal é repetir com várias sementes.
- *Ótimos na borda do espaço de busca* (Seção 2): a busca não está esgotada.
- *Sem conjunto de teste:* o treino e a avaliação usam os mesmos pixels, o que é adequado à compressão da própria imagem, mas não mede generalização para outras imagens.
- *Redução de resolução* para 128 px no lado menor: os resultados absolutos podem mudar em resoluções maiores.

5. Conclusão

Recomendamos o **GNG** para a quantização de cores: nas 5 imagens ele obteve QE menor que o SOM em todos os tamanhos de rede, com ganho médio de PSNR de +0,9, +3,0 e +5,3 dB (16, 64 e 256 neurônios), erro topológico menor e melhor preservação de cores raras (como o carro vermelho de `corRara`), além de ser pouco sensível aos hiperparâmetros, ao passo que o SOM depende fortemente do raio da vizinhança. O custo é um treino mais lento ($\approx 2{,}7\times$ com 256 neurônios), e com apenas 16 cores a diferença entre os métodos é pequena, de modo que o SOM, mais simples e rápido, é uma alternativa razoável nesse caso. Essas conclusões se baseiam em 5 imagens e uma única semente por configuração, e devem ser confirmadas com mais imagens e repetições.

A. Todas as reconstruções (5 imagens $\times$ 6 redes = 30)

Cada figura mostra a imagem original (topo) e, abaixo, as reconstruções com a melhor configuração de hiperparâmetros de cada rede (menor QE): **GNG à esquerda e SOM à direita**, com $K = 16$, 64 e 256 neurônios (cores). Sobre cada reconstrução estão o QE, o PSNR e o SSIM.

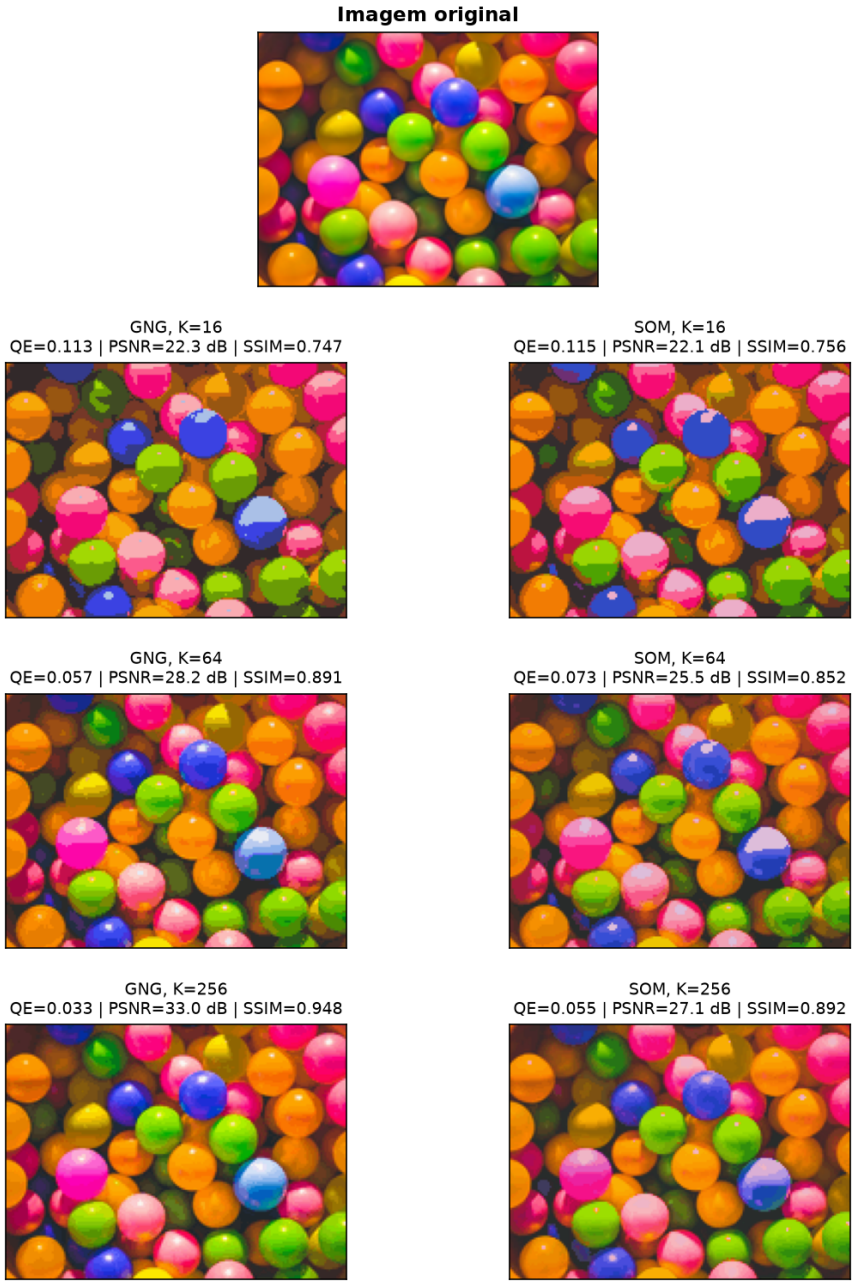


Figure 7: `altaSaturacao`: original e reconstruções GNG (esquerda) e SOM (direita) para $K = 16$, 64 e 256.

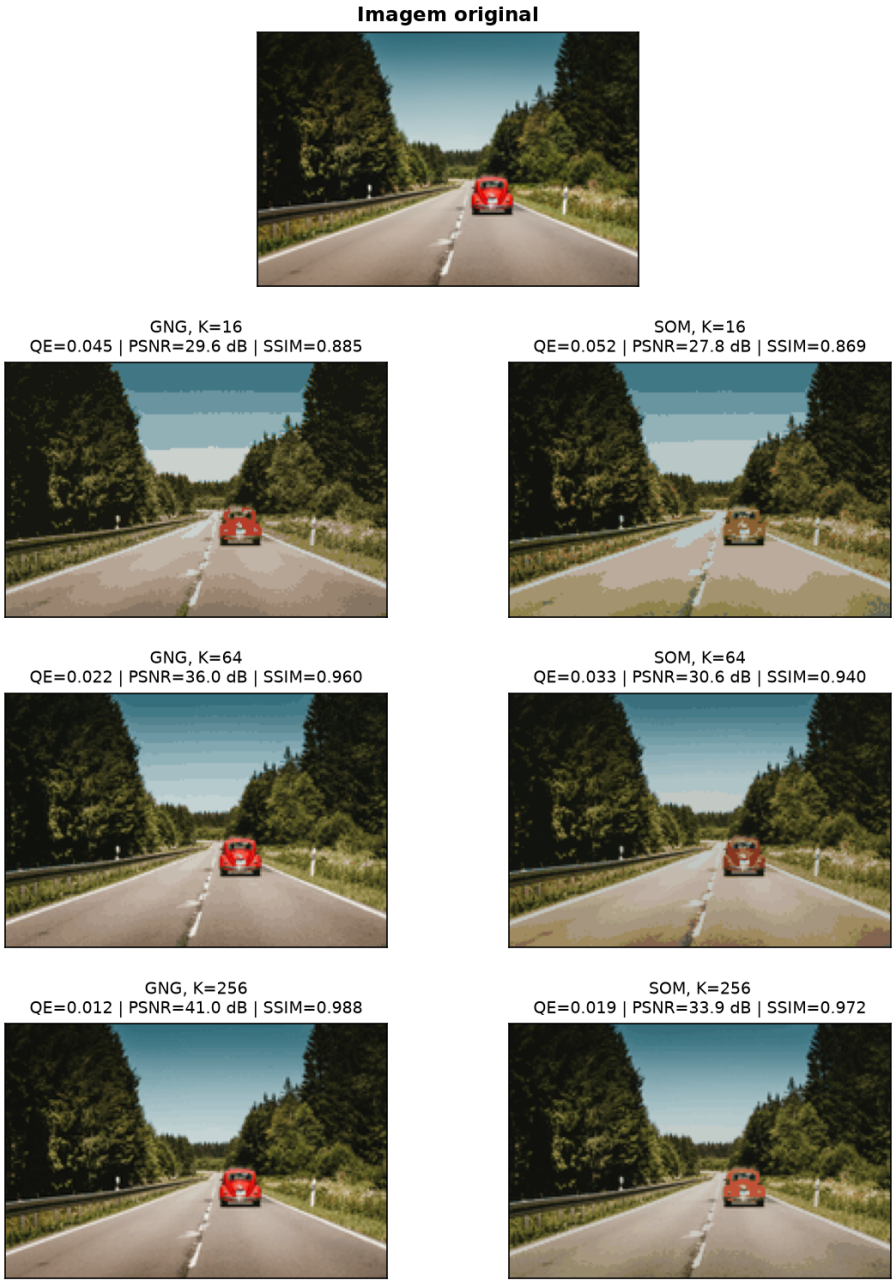


Figure 8: `corRara`: original e reconstruções GNG (esquerda) e SOM (direita) para $K = 16$, 64 e 256.

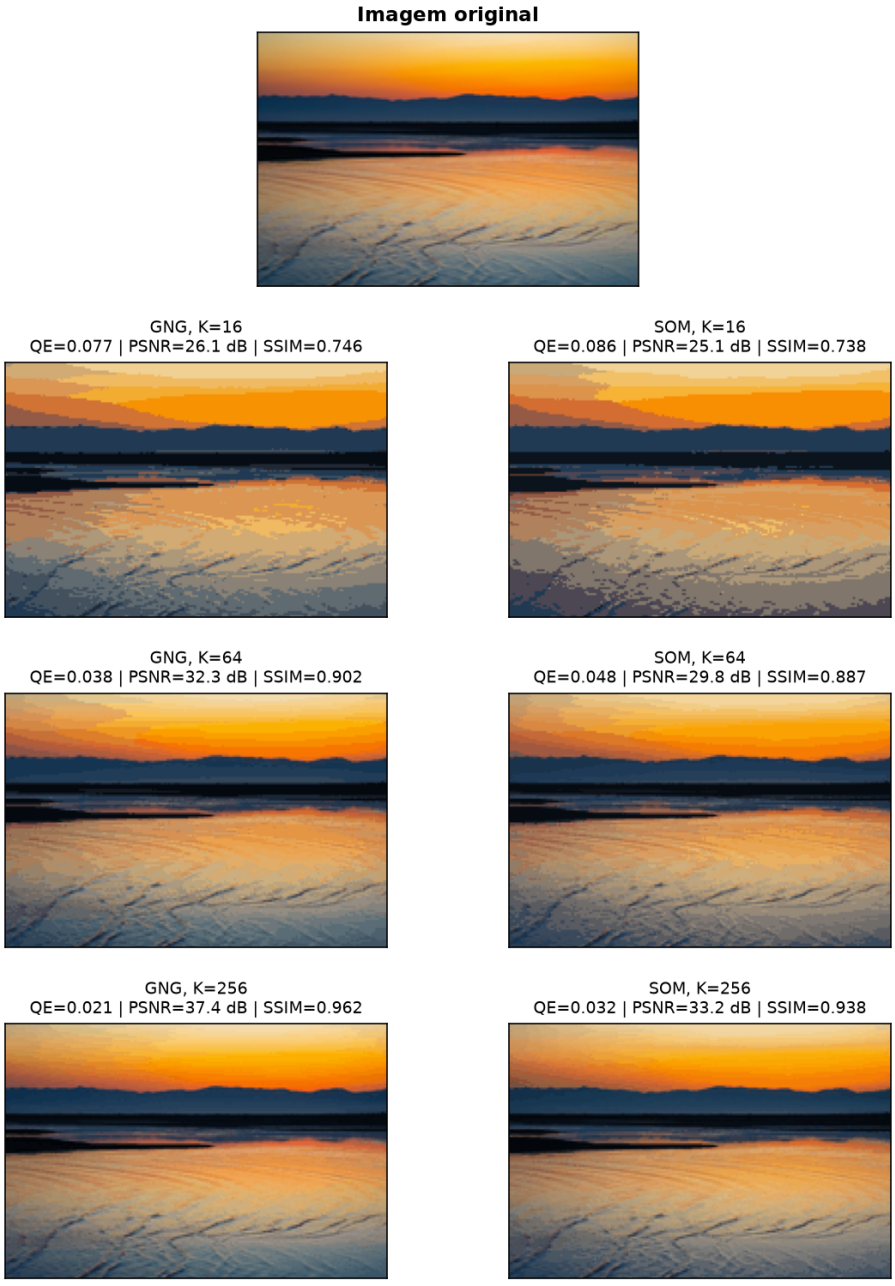


Figure 9: `paisagem`: original e reconstruções GNG (esquerda) e SOM (direita) para $K = 16$, 64 e 256.



Figure 10: `paisagem2`: original e reconstruções GNG (esquerda) e SOM (direita) para $K = 16$, 64 e 256.



Figure 11: `retratoHumano`: original e reconstruções GNG (esquerda) e SOM (direita) para $K = 16$, 64 e 256.