Projeto 3: Modelo Generativo (VAE) no Fashion-MNIST

Disciplina: Redes Neurais Artificiais — UNIFESP

Autor(es): Beatriz Prado Soche (RA: 176112)

Repositório / Código Reprodutível: https://github.com/biaaPrado/redes-neurais/tree/main/Projeto%203%20-%20Generativo%20(VAE)

1. Configuração Experimental e Reprodutibilidade

1.1. Dados e Pré-processamento

Foi utilizado o **Fashion-MNIST**: 70 000 imagens em tons de cinza de 28×28 pixels, de 10 classes (camiseta/top, calça, pulôver, vestido, casaco, sandália, camisa, tênis, bolsa e bota). Cada imagem foi achatada em um vetor de 784 pixels e normalizada para $[0, 1]$ dividindo-se por 255. Como essa normalização é uma constante fixa (não estima média nem desvio dos dados), não há risco de vazamento de dados (*data leakage*).

As 60 000 imagens do conjunto de treino original foram divididas aleatoriamente (semente 42) em **48 000 para treino (80%)** e **12 000 para validação (20%)**. A validação foi usada para escolher a topologia, os hiperparâmetros e a parada do treino. As **10 000 imagens do conjunto de teste oficial** foram usadas somente na avaliação final e na análise do espaço latente.

1.2. Modelo (VAE) e Função de Custo

O VAE é formado por um *encoder*, que mapeia a imagem $\mathbf{x} \in \mathbb{R}^{784}$ para os parâmetros de uma gaussiana $q(\mathbf{z}|\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}, \mathrm{diag}(\boldsymbol{\sigma}^2))$ no espaço latente de dimensão $d \in \{2, 8\}$, e por um *decoder*, que reconstrói a imagem a partir de $\mathbf{z}$. O *encoder* é uma MLP (camadas densas com ReLU) cujas últimas saídas são $\boldsymbol{\mu}$ e $\log \boldsymbol{\sigma}^2$; o *decoder* é o espelho do *encoder* e termina em 784 saídas passadas por uma sigmoide. A amostragem usa o truque da reparametrização, $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\varepsilon}$, com $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$, o que permite propagar o gradiente.

O custo é o negativo do limite inferior da evidência (ELBO), com $\beta = 1$:

$$\mathcal{L}(\mathbf{x}) = \underbrace{-\sum_{j=1}^{784} \left[x_j \log \hat{x}_j + (1 - x_j) \log(1 - \hat{x}_j) \right]}_{\text{reconstrução (entropia cruzada binária)}} + \underbrace{\left(-\tfrac{1}{2} \sum_{k=1}^{d} \left(1 + \log \sigma_k^2 - \mu_k^2 - \sigma_k^2 \right) \right)}_{\mathrm{KL}(q(\mathbf{z}|\mathbf{x}) \,\|\, \mathcal{N}(\mathbf{0},\mathbf{I}))}. \tag{1}$$

Todos os custos reportados são **médias por imagem**. O termo de reconstrução mede a fidelidade da imagem; o KL aproxima o espaço latente de $\mathcal{N}(\mathbf{0}, \mathbf{I})$, o que permite gerar imagens novas sorteando $\mathbf{z}$. O treino usou o otimizador Adam, *early stopping* sobre o custo de validação e, ao final, restauração dos pesos da melhor época.

1.3. Busca de Hiperparâmetros e Refinamento

Para cada dimensão latente ($d = 2$ e $d = 8$), a topologia foi ajustada de forma independente, variando as camadas ocultas, a taxa de aprendizado e o tamanho do lote (Tabela 1). A melhor configuração foi escolhida pelo **menor custo no conjunto de validação**, totalizando $2 \times 16 = 32$ treinamentos.

Como os melhores modelos da busca pararam nas épocas 38 e 39 (de um limite de 40), não foi possível afirmar que tivessem convergido, e por isso realizou-se um **experimento de refinamento**: apenas a melhor configuração de cada d foi retreinada do zero, com a mesma semente, com até 150 épocas e paciência 10. Como a semente é a mesma, as primeiras épocas reproduzem o treino da busca, e o refinamento apenas o estende. Os modelos refinados são os **modelos finais** usados na análise do espaço latente. Os resultados ficam em duas pastas: `resultados_vae/` (busca, até 40 épocas) e `resultados_vae_refinado/` (modelos refinados).

Table 1: Espaço de hiperparâmetros da busca e melhor configuração de cada espaço latente.

Componente	**Valores testados**	**Melhor (menor custo na validação)**
Dimensão latente d	2; 8 (buscas independentes)	—
Topologia (ocultas do *encoder*; *decoder* espelhado)	256; 256-128; 512-256; 512-256-128	$d = 2$: 512-256-128; $d = 8$: 512-256
Taxa de aprendizado (Adam)	5×10^{-4}; 10^{-3}	5×10^{-4} (ambos)
Tamanho do lote	128; 256	128 (ambos)
Função de custo	BCE + β·KL, $\beta = 1$	—
Critério de parada	*Early stopping* (paciência 5), máx. 40 épocas	—
Semente aleatória	42	—

1.4. Avaliação do Espaço Latente

A representação latente de cada imagem de teste é a média $\boldsymbol{\mu}$ de $q(\mathbf{z}|\mathbf{x})$. Para $d = 8$, a projeção em 2D foi feita por PCA, **ajustado nos dados de treino** e aplicado ao teste, reportando-se a variância explicada. Para quantificar clusters e separação de rótulos, usaram-se: (i) **silhouette** com os rótulos (de -1 a 1; quanto maior, mais coesas e separadas as classes); (ii) **NMI** entre os 10 grupos do k-means (sem usar rótulos) e os rótulos (de 0 a 1); (iii) **acurácia do kNN** ($k = 5$, treinado nas representações do treino e avaliado no teste), que mede a separabilidade dos rótulos; e (iv) o número de **dimensões ativas** (variância da média $> 0{,}01$).

2. Busca de Hiperparâmetros e Convergência

A Figura 1 mostra o custo de validação de cada uma das 32 configurações e a Figura 2 as curvas de treino e validação dos melhores modelos da busca. A busca completa levou cerca de 88 minutos em CPU.

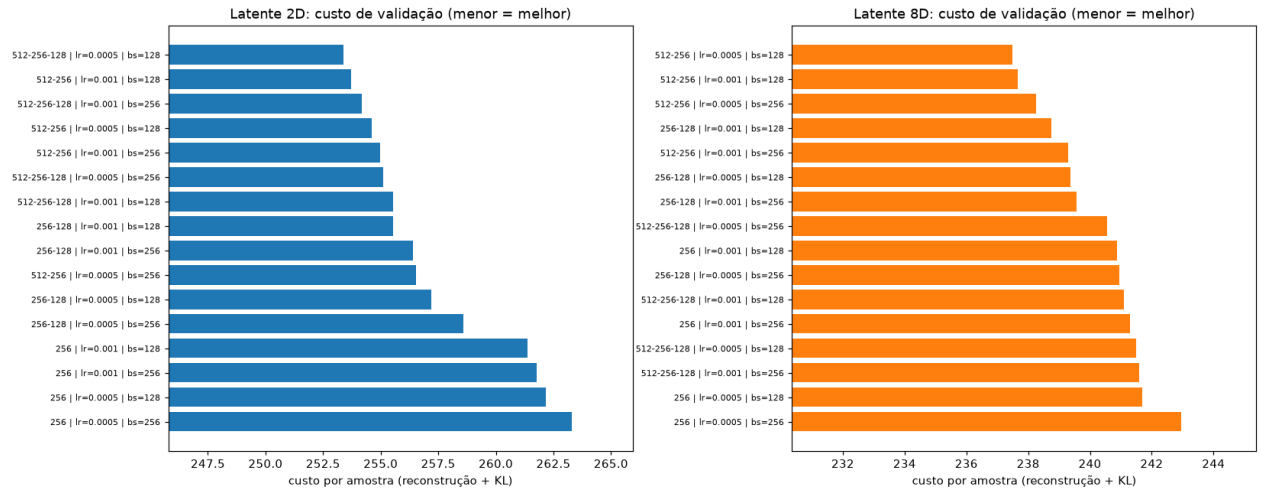


Figure 1: Custo de validação por configuração (menor é melhor), para $d = 2$ (esquerda) e $d = 8$ (direita).

Table 2: Custo de validação médio por topologia (média sobre as taxas de aprendizado e os lotes).

Latente	**256**	**256-128**	**512-256**	**512-256-128**
$d = 2$	262,16	256,93	254,96	**254,55**
$d = 8$	241,70	239,66	**238,17**	241,19

Análise Crítica:

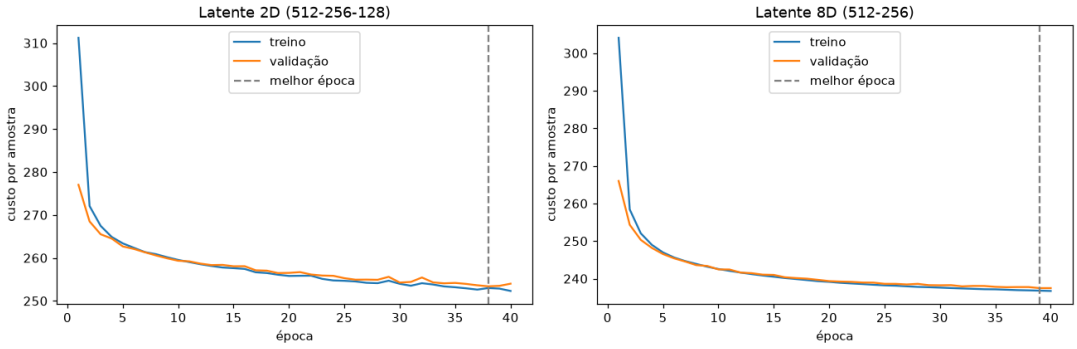


Figure 2: Custo de treino e de validação por época dos melhores modelos da busca (linha tracejada: melhor época).

- **Topologia:** foi o fator que mais pesou (Tabela 2). Com $d = 2$, a rede de uma só camada oculta foi a pior (média 262,2), e as três mais profundas ficaram entre 254,5 e 256,9. Com $d = 8$, a melhor foi a `512-256` (238,2); a mais profunda (`512-256-128`, 241,2) ficou atrás dela. Hipótese (não testada): a rede mais profunda converge mais devagar e foi penalizada pelo limite de 40 épocas.
- **Tamanho do lote e taxa de aprendizado:** o lote 128 superou o 256 em 7 de 8 pares (mesma topologia e taxa), nos dois espaços latentes; uma explicação plausível é o maior número de atualizações por época sob um orçamento fixo de épocas. A taxa de aprendizado teve efeito pequeno: as médias de 10^{-3} e 5×10^{-4} diferem em menos de 1 ponto de custo.
- **Sensibilidade geral:** o custo variou apenas 3,9% ($d = 2$: de 253,4 a 263,3) e 2,3% ($d = 8$: de 237,5 a 243,0) entre as 16 configurações de cada d. As três melhores configurações ficaram a menos de 1 ponto entre si ($d = 2$: 253,38; 253,72; 254,20; $d = 8$: 237,48; 237,66; 238,26), o que, com uma única semente, está no nível do ruído; a escolha entre elas é frágil.
- **Sobreajuste e convergência:** as curvas de treino e validação ficam praticamente sobrepostas (Figura 2), sem sinal de sobreajuste. Por outro lado, a melhor época foi a 38 ($d = 2$) e a 39 ($d = 8$) de 40, isto é, o limite de épocas foi quase atingido e não foi possível afirmar a convergência, o que motivou o refinamento (Seção 3).

3. Refinamento com Mais Épocas

A Tabela 3 compara os melhores modelos da busca (até 40 épocas) com os modelos retreinados com mais épocas. A coluna de épocas indica a melhor época e o total de épocas rodadas.

Table 3: Melhores modelos: busca (até 40 épocas) × refinamento (custos médios por imagem).

Etapa	**Topologia**	**Épocas**	**Custo val.**	**Custo teste**	**Reconstr.**	**KL**
Latente $d = 2$						
Busca (40 ép.)	512-256-128	38/40	253,38	254,93	248,22	6,71
Refinado	512-256-128	38/48	253,38	254,99	248,28	6,71
Latente $d = 8$						
Busca (40 ép.)	512-256	39/40	237,48	239,14	225,98	13,16
Refinado	512-256	88/98	**236,20**	**237,87**	224,86	13,01

Análise Crítica do Refinamento:

- $d = 2$ **já havia convergido:** o *early stopping* disparou na época 48, dez épocas depois da melhor (38), que é a mesma da busca. O custo de validação é idêntico (253,38) e as métricas do espaço latente (Tabela 4) também; ou seja, o modelo refinado é o mesmo da busca. A diferença

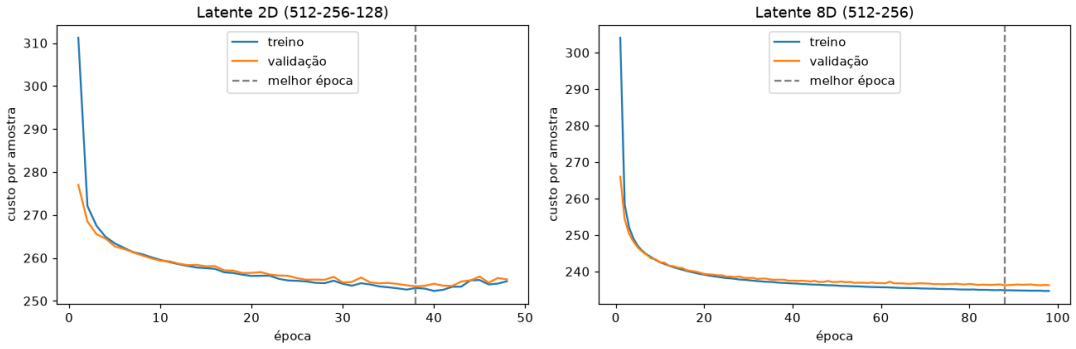


Figure 3: Curvas de treino e validação dos modelos refinados.

de 0,06 no custo de teste (254,93 → 254,99) vem da amostragem aleatória de $\mathbf{z}$ no cálculo do custo, já que o KL (6,71) é idêntico. Depois da época 38, os custos de treino e de validação apenas oscilam em torno de 254 (Figura 3).

- $d = 8$ **melhorou pouco:** o custo de validação caiu de 237,48 para 236,20 ($-1{,}28$; $-0{,}54\%$) e o de teste de 239,14 para 237,87 ($-0{,}53\%$), com a reconstrução indo de 225,98 para 224,86 e o KL de 13,16 para 13,01. A melhor época foi a 88 e o *early stopping* disparou na 98, de modo que o treino convergiu pelo critério adotado. O custo refinado é menor que o de todas as 32 configurações da busca (o menor era 237,48).
- **Sobreajuste:** no 8D, as curvas de treino e validação se afastam levemente ao longo das épocas (diferença de cerca de 1 a 2 pontos no final, por leitura visual da figura), mas o custo de validação não volta a subir de forma relevante, de modo que não há sobreajuste importante.
- **Ressalva:** o ganho de 1,28 ponto no 8D é maior que a diferença entre as três melhores configurações da busca (menos de 1 ponto). Como apenas a vencedora foi refinada, não se sabe se outra configuração, treinada por mais épocas, a superaria.

4. Espaço Latente e Qualidade Generativa

4.1. Clusters, Separação de Rótulos e Variância Explicada

A Tabela 4 reúne as métricas calculadas no conjunto de teste, e as Figuras 4 e 5 mostram as representações coloridas pelos rótulos. As figuras e a análise abaixo são dos **modelos finais (refinados)**; a tabela inclui também os valores da busca, para comparação. As métricas do $d = 2$ coincidem nas duas etapas, pois o modelo é o mesmo.

Table 4: Métricas do espaço latente no conjunto de teste. Acaso do kNN: 0,10.

Etapa	**Representação**	**Silhouette**	**NMI (k-means)**	**Acurácia kNN**	**Dim. ativas**
Busca (40 ép.)	Latente 2D	0,121	0,563	0,713	2/2
Busca (40 ép.)	Latente 8D (completo)	0,067	0,526	0,834	7/8
Busca (40 ép.)	Latente 8D → PCA 2D	−0,002	0,456	0,479	—
Refinado	Latente 2D	0,121	0,563	0,713	2/2
Refinado	Latente 8D (completo)	0,063	0,484	0,835	7/8
Refinado	Latente 8D → PCA 2D	−0,031	0,414	0,439	—

Observações.

- **Espaço 2D:** os pontos se organizam em regiões por categoria, dispostas como "pétalas" ao redor da origem (efeito do termo KL, que aproxima o espaço de $\mathcal{N}(\mathbf{0}, \mathbf{I})$). Os calçados (sandália, tênis, bota) ocupam a esquerda, vizinhos entre si; a calça fica no alto; a bolsa, embaixo; e as roupas de

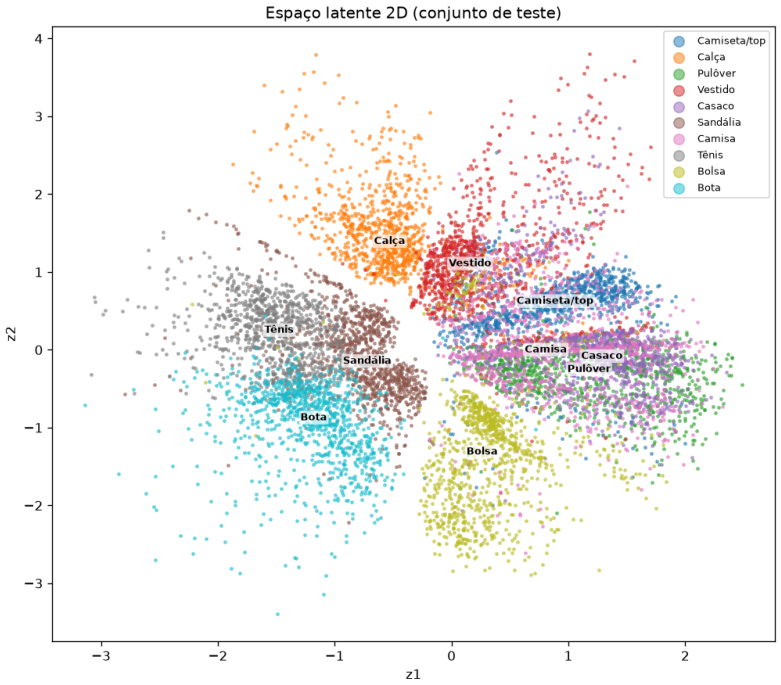


Figure 4: Espaço latente de 2 dimensões (conjunto de teste), colorido pelos rótulos.

parte de cima (camiseta, camisa, pulôver, casaco) ficam à direita, muito sobrepostas. O vestido ocupa o centro, sobrepondo-se em parte à calça e à camiseta.

- **Projeção PCA do 8D:** as classes aparecem mais misturadas que no espaço 2D (calçados sobrepostos entre si, calça e vestido sobrepostos, e camisa, pulôver e casaco sobrepostos), em linha com a queda da acurácia do kNN de 0,835 (8D completo) para 0,439 (PCA 2D).

- **Variância explicada:** as duas primeiras componentes explicam apenas **33,8%** da variância (17,8% + 15,9%); seis componentes são necessárias para chegar a 88,3%, e sete somam $\approx 100\%$. A oitava componente tem variância desprezível (2×10^{-5}, ou 0,002%), coerente com as 7 dimensões ativas (de 8): uma dimensão foi ignorada pelo modelo (*posterior collapse*). A variância é distribuída de forma quase uniforme entre as sete componentes ativas (de 11,7% a 17,8%), como esperado quando o KL aproxima o espaço latente de uma gaussiana isotrópica. Na busca (40 épocas), as duas primeiras componentes somavam 34,8%.

4.2. Reconstrução e Geração de Imagens

A Figura 6 compara imagens originais com suas reconstruções, e a Figura 7 mostra imagens *novas* geradas sorteando $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$. A Figura 8 decodifica uma grade regular do espaço 2D.

- **Reconstruções:** são borradas nos dois modelos (típico de VAEs), mas o de 8D preserva mais detalhes (por exemplo, a textura listrada do casaco aparece no 8D e quase desaparece no 2D); o logotipo da camiseta é perdido nos dois.

- **Geração:** com $d = 2$ as amostras são plausíveis, porém pouco variadas (muitas botas, bolsas e camisetas); com $d = 8$ há maior variedade e detalhe, mas alguns exemplares saem distorcidos.

- **Variedade 2D:** a transição entre peças é suave e organizada: botas embaixo à esquerda, tênis e sandálias no alto à esquerda, calças no alto, camisetas no alto à direita, blusas e casacos embaixo à direita e bolsas embaixo ao centro. Isso indica que o espaço latente é contínuo e semanticamente estruturado. Nas bordas da grade (fora da região com dados), as imagens se repetem.

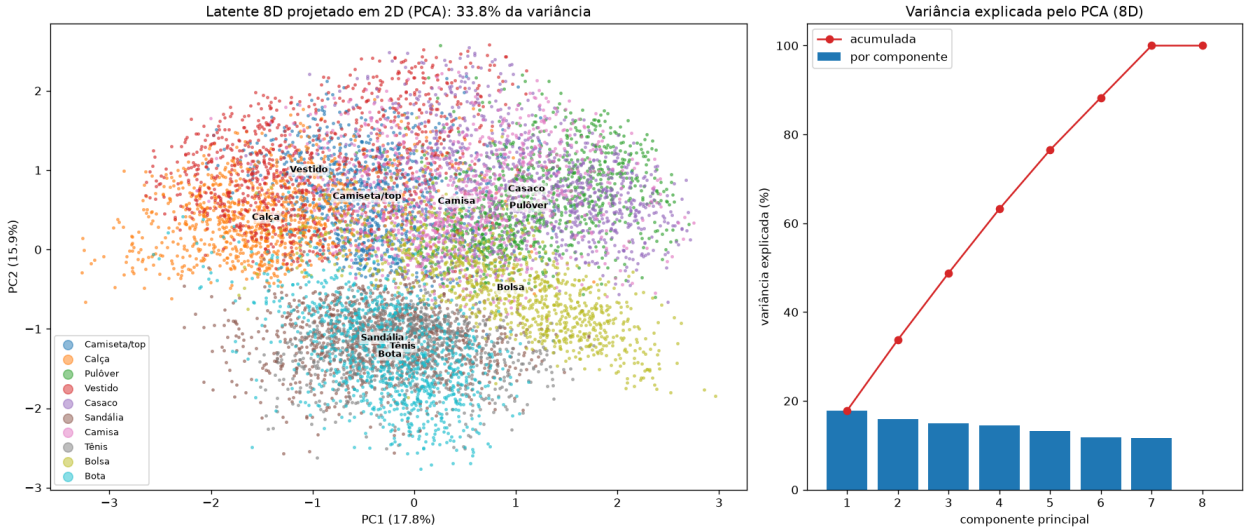


Figure 5: Projeção PCA do espaço latente de 8 dimensões (esquerda) e variância explicada por componente (direita).

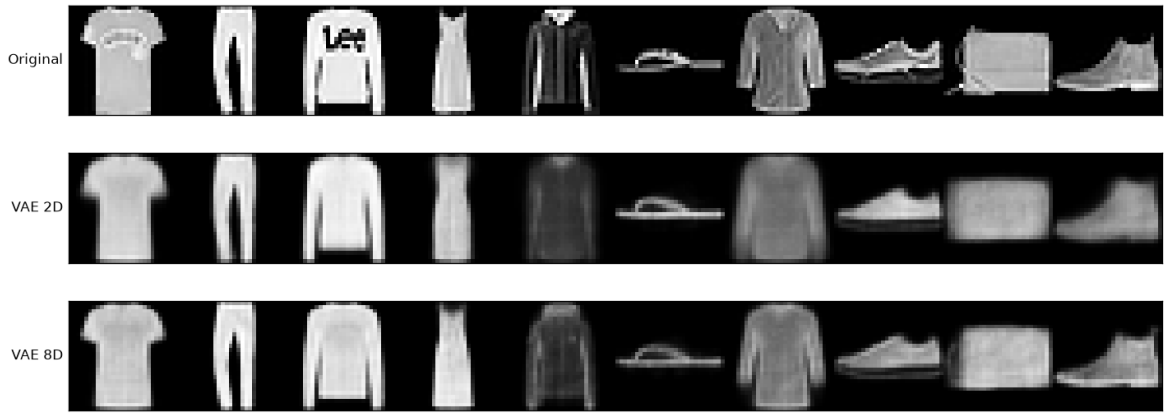


Figure 6: Imagens de teste originais (topo) e reconstruções pelos VAEs de 2D e 8D.

5. Discussão e Lições Aprendidas

- **Espaço latente de 2 × 8 dimensões:** nos modelos finais, o VAE de 8 dimensões atingiu custo de teste 6,7% menor (237,87 contra 254,99), por reconstruir melhor (reconstrução −9,4%: 248,3 → 224,9), ao custo de um KL quase duas vezes maior (6,7 → 13,0): com mais dimensões, o modelo guarda mais informação sobre a imagem. As buscas foram independentes, mas o 8D tem mais capacidade, então o resultado é esperado. O 2D tem a vantagem de ser diretamente visualizável e de permitir a varredura da variedade (Figura 8).

- **Há formação de clusters?** *Parcialmente.* Não há clusters limpos e isolados, mas regiões por **macrocategoria**: calçados, roupas de parte de cima, calças, vestidos e bolsas (Figura 4). O NMI do k-means é moderado (0,563 no 2D; 0,484 no 8D) e o silhouette é baixo (0,121 e 0,063), o que confirma que os grupos não são bem separados.

- **Há separação dos rótulos?** *Sim, mas parcial.* A acurácia do kNN é muito superior ao acaso (0,10): 0,713 no 2D e 0,835 no 8D. A separação é boa *entre* categorias (calçados, calças, bolsas e roupas de cima) e fraca *dentro* de categorias semelhantes: camisa, pulôver e casaco se sobrepõem quase por completo, e a camiseta se mistura à camisa. O 8D separa melhor que o 2D (informação extra), e a projeção PCA do 8D **subestima** essa separação (0,439). O silhouette é menor no 8D

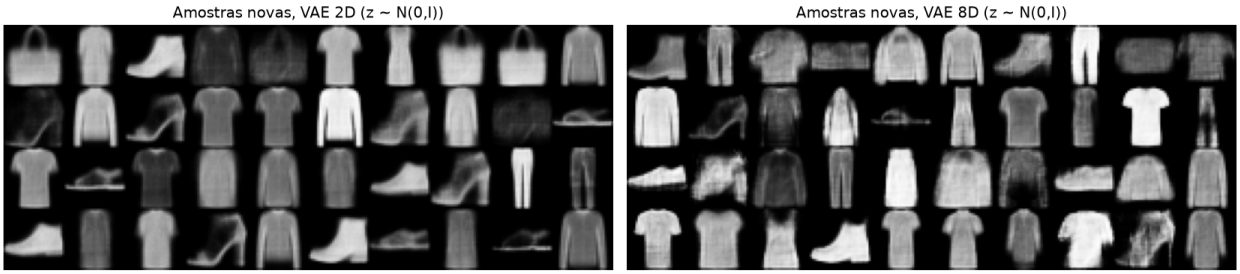


Figure 7: Imagens geradas por amostragem $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ (VAE 2D à esquerda, 8D à direita).

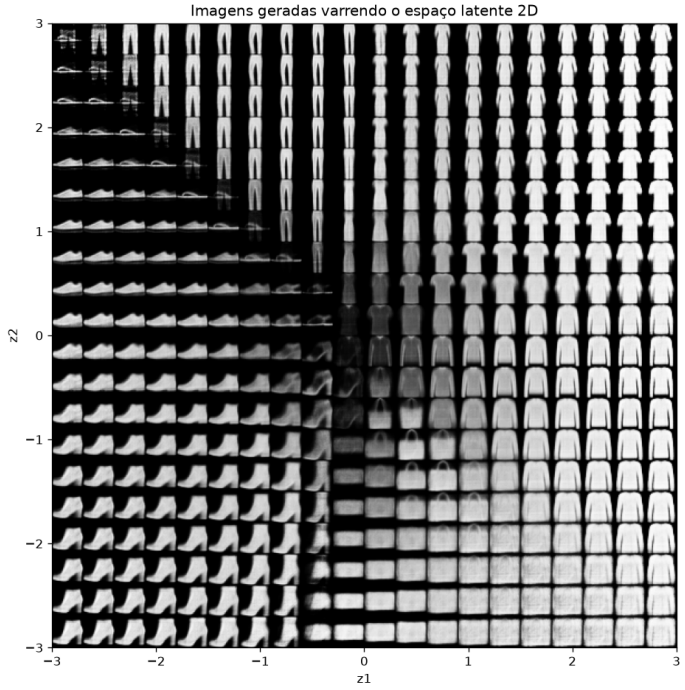


Figure 8: Imagens geradas varrendo uma grade de $[-3, 3]^2$ no espaço latente 2D.

que no 2D enquanto o kNN é maior: as duas métricas medem coisas diferentes (compacidade global dos grupos *versus* vizinhança local), e por isso ambas são reportadas.

- **Quanto da variância a projeção ilustra?** A projeção 2D (PCA) do espaço de 8 dimensões ilustra apenas **33,8%** da variância, de modo que a maior parte da informação do espaço latente fica fora do gráfico. A variância está bem distribuída entre as componentes (a primeira explica só 17,8%), o que explica por que a projeção perde muita estrutura de classes.

- **Dimensão ignorada:** uma das 8 dimensões latentes foi desativada pelo modelo (variância ≈ 0), o que sugere que 7 dimensões bastam para esta tarefa com esta arquitetura.

- **Hiperparâmetros:** o resultado é pouco sensível à escolha (variação de 2 a 4% no custo), sendo a topologia o fator mais relevante, seguida do tamanho do lote; a taxa de aprendizado teve efeito pequeno.

- **Efeito do refinamento:** treinar por mais épocas não alterou o $d = 2$ (já havia convergido na época 38) e reduziu em apenas 0,5% o custo do $d = 8$. Esse ganho de reconstrução **não** se traduziu em melhor separação dos rótulos: no 8D, a acurácia do kNN ficou praticamente igual (0,834 $\rightarrow$ 0,835), enquanto o NMI (0,526 $\rightarrow$ 0,484), o silhouette (0,067 $\rightarrow$ 0,063), o kNN na projeção PCA (0,479 $\rightarrow$ 0,439) e a variância das duas primeiras componentes (34,8% $\rightarrow$ 33,8%)

diminuíram levemente. Faz sentido, pois o VAE é treinado sem usar rótulos: um custo menor significa melhor reconstrução, e não necessariamente classes mais separadas. Como hipótese (não testada), mais treino distribui a informação de forma mais uniforme entre as dimensões, enfraquecendo as direções principais. As diferenças em NMI e silhouette são pequenas e vêm de uma única execução do k-means, devendo ser lidas com cautela. De qualquer forma, as conclusões qualitativas (agrupamento parcial por macrocategoria, 8D melhor que 2D, projeção PCA pouco informativa) não mudam.

- **Limitações:**
  - *Uma semente por configuração* (42): diferenças pequenas, como entre as três melhores configurações da busca, podem ser ruído.
  - *Refinamento só da vencedora:* apenas a melhor configuração de cada d foi retreinada por mais épocas; a ordem entre as configurações poderia mudar se todas fossem treinadas até a convergência.
  - *Critério de escolha:* o modelo foi escolhido apenas pelo custo de validação; a qualidade do espaço latente (clusters, separação) foi analisada depois e não influenciou a escolha.
  - *Arquitetura e custo:* foram usadas apenas MLPs, com $\beta = 1$ fixo e entropia cruzada binária aplicada a pixels em tons de cinza (prática padrão, mas não exatamente uma verossimilhança de dados binários); o borrão nas reconstruções é uma limitação conhecida desse formato.
  - *PCA é linear:* a projeção pode não capturar estruturas não lineares do espaço latente.
  - *Métricas do espaço latente:* o silhouette foi calculado numa amostra de 5 000 pontos do teste, e o k-means foi executado uma vez (semente fixa).

6. Conclusão

O VAE de 8 dimensões (`512-256`, refinado) obteve o menor custo (237,87 no teste, contra 254,99 do VAE de 2 dimensões) e melhor separabilidade dos rótulos (kNN 0,835 contra 0,713), enquanto o de 2 dimensões permite visualizar diretamente o espaço latente e gerar uma variedade contínua e organizada. Em ambos, o espaço latente forma agrupamentos parciais por macrocategoria (calçados, calças, bolsas e roupas de parte de cima), com forte sobreposição entre camisa, pulôver e casaco, e a projeção PCA do espaço de 8 dimensões ilustra só 33,8% da variância. Treinar por mais épocas não mudou o modelo de 2 dimensões e reduziu em apenas 0,5% o custo do de 8, sem melhorar a separação dos rótulos.